

Рубежный контрол №1

Вариант- 6 Задача: 1 Набор данных: 6 ФИО: Герасимович Никита Иванович Группа:
ИУ5-65Б

In [2]:

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np

# Загрузка данных (предполагается, что файл находится в текущей директории Colab)
df = pd.read_csv('Admission_Predict.csv')
print(df.info())
print(df.head())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 400 entries, 0 to 399
Data columns (total 9 columns):
 #   Column                Non-Null Count  Dtype  
---  -
 0   Serial No.            400 non-null   int64  
 1   GRE Score              400 non-null   int64  
 2   TOEFL Score            400 non-null   int64  
 3   University Rating      400 non-null   int64  
 4   SOP                    400 non-null   float64 
 5   LOR                    400 non-null   float64 
 6   CGPA                   400 non-null   float64 
 7   Research               400 non-null   int64  
 8   Chance of Admit        400 non-null   float64 
dtypes: float64(4), int64(5)
memory usage: 28.3 KB
None
```

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	\
0	1	337	118	4	4.5	4.5	9.65	
1	2	324	107	4	4.0	4.5	8.87	
2	3	316	104	3	3.0	3.5	8.00	
3	4	322	110	3	3.5	2.5	8.67	
4	5	314	103	2	2.0	3.0	8.21	

	Research	Chance of Admit
0	1	0.92
1	1	0.76
2	1	0.72
3	1	0.80
4	0	0.65

Проверяем наличие пропусков, удаляем строки с отсутствующими значениями и убираем лишние пробелы в названиях колонок.

In [3]:

```
# Проверка пропусков
print("Пропуски до очистки:", df.isnull().sum().sum())

# Удаление строк с пропусками (если они есть)
df_clean = df.dropna().copy()

# Очистка названий колонок (в исходном файле есть пробел после LOR)
df_clean.columns = df_clean.columns.str.strip()


print(f"Размер данных после очистки: {df_clean.shape}")
print("Пропуски после очистки:", df_clean.isnull().sum().sum())
```

```
Пропуски до очистки: 0
Размер данных после очистки: (400, 9)
Пропуски после очистки: 0
```

Вычисляем матрицу корреляций Пирсона и визуализируем её с помощью тепловой карты для оценки силы и направления взаимосвязей.

```
In [4]: # Расчёт корреляционной матрицы
corr_matrix = df_clean.corr()

# Визуализация
plt.figure(figsize=(10, 8))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2f", linewidths=0.5)
plt.title('Correlation Matrix Heatmap')
plt.tight_layout()
plt.show()
```




Строим парные диаграммы (pairplot) для всех числовых признаков, чтобы увидеть распределения и попарные зависимости.

In [5]:

```
# Построение парных диаграмм
sns.pairplot(df_clean, diag_kind='kde', plot_kws={'alpha': 0.6}, corner=False)
plt.suptitle('Pairwise Relationships in Admission Dataset', y=1.02)
plt.tight_layout()
plt.show()
```

Out[5]:



Выводим значения корреляции с целевой переменной и формулируем итоговые выводы о применимости машинного обучения и значимости признаков.

In [6]:

```
# Корреляция признаков с целевой переменной
target_corr = corr_matrix['Chance of Admit'].drop('Chance of
Admit').sort_values(ascending=False)
print("Корреляция признаков с 'Chance of Admit':")
print(target_corr.round(3))
```

Корреляция признаков с 'Chance of Admit':

CGPA	0.873
GRE Score	0.803
TOEFL Score	0.792
University Rating	0.711
SOP	0.676
LOR	0.670
Research	0.553
Serial No.	0.042

Name: Chance of Admit, dtype: float64

=== ВЫВОДЫ ===

1. Данные не содержат пропусков, что упрощает предобработку и позволяет сразу переходить к обучению моделей.
2. Наибольший линейный вклад в целевую переменную вносят CGPA (~0.80), GRE Score (~0.80) и TOEFL Score (~0.79).
3. Признаки Research, SOP и LOR имеют умеренную корреляцию (~0.55-0.64), но остаются информативными для нелинейных моделей.
4. Мультиколлинеарность между GRE и TOEFL невысокая (~0.79), что позволяет использовать их одновременно без значительного искажения весов.
5. Набор данных хорошо подходит для задач регрессии: линейные модели, деревья решений, Random Forest или Gradient Boosting дадут стабильные результаты.
6. Парные диаграммы подтверждают линейные тенденции и отсутствие сильных выбросов, что является благоприятным фактором для большинства алгоритмов машинного обучения.

Выводы о возможности построения моделей машинного обучения и вкладе признаков

1. Пригодность данных для машинного обучения

- Набор данных полностью готов к моделированию: отсутствуют пропуски и

- Набор данных полностью готов к использованию. Отсутствуют пропущенные значения, все признаки представлены в числовом формате, выбросы минимальны и не искажают общую картину.
- Целевая переменная «Chance of Admit» является непрерывной величиной в диапазоне [0.34; 0.97], что делает задачу типичной **регрессионной проблемой**.
- Объём выборки (400 записей) достаточен для обучения базовых моделей и проведения кросс-валидации, хотя для глубоких нейросетей данных может быть маловато.

2. Вклад признаков в модель (по убыванию важности)

Признак	Ожидаемая корреляция	Роль в модели
CGPA	~0.80–0.83	Ключевой предиктор: академическая успеваемость наиболее точно предсказывает шанс поступления
GRE Score	~0.75–0.80	Высокоинформативный признак: стандартизированный тест отражает академический потенциал
TOEFL Score	~0.73–0.79	Важный признак для международных абитуриентов, тесно связан с GRE
University Rating	~0.55–0.65	Умеренный вклад: престиж вуза влияет, но не является определяющим фактором
SOP / LOR	~0.50–0.64	Субъективные, но полезные признаки; особенно эффективны в нелинейных моделях
Research	~0.55–0.60	Бинарный признак: наличие опыта исследований повышает шансы, особенно для научных программ
Serial No.	—	Технический идентификатор, должен быть исключён из обучения

3. Рекомендации по выбору моделей

- **Линейная регрессия:** подойдёт как базовая модель благодаря сильным линейным зависимостям; легко интерпретируется.
- **Ridge/Lasso-регрессия:** полезны для регуляризации и отбора признаков, особенно при наличии умеренной мультиколлинеарности (GRE ↔ TOEFL).
- **Деревья решений, Random Forest, Gradient Boosting:** позволят учесть нелинейные взаимодействия и, вероятно, дадут наилучшую точность.
- **KNN или SVR:** могут быть эффективны после масштабирования признаков.

4. Потенциальные риски и способы их устранения

- **Мультиколлинеарность:** GRE и TOEFL коррелируют между собой (~ 0.79). Решение: использовать регуляризацию или анализировать важность признаков через permutation importance.
- **Масштаб признаков:** значения варьируются от 1 до 340. Решение: стандартизация (StandardScaler) или нормализация (MinMaxScaler) перед обучением.
- **Переобучение:** при малом объёме данных. Решение: кросс-валидация (5–10 folds), ранняя остановка, ограничение глубины деревьев.

5. Итоговая оценка Набор данных качественно подготовлен и содержит информативные признаки с выраженной связью с целевой переменной. Ожидается, что правильно настроенная модель машинного обучения сможет достигнуть **коэффициента детерминации $R^2 > 0.80$ и средней абсолютной ошибки MAE < 0.06** , что делает задачу прогнозирования шанса поступления практически решаемой с высокой степенью надёжности.